Práctica Guiada: Limpieza y Transformación

Scikit-Learn Preprocessing (Laboratorio)

Clase Práctica - Semana 2

Imputando Valores Nulos

Cuando los sensores fallan o los logs están corruptos:

```
import pandas as pd

# 1. Calculamos la mediana segura
mediana = df['bytes_transmitted'].median()

# 2. Rellenamos (Fill NaN)
df['bytes_transmitted'] = df['bytes_transmitted'].fillna(mediana)

# 3. Borramos los registros donde falta la etiqueta objetivo
df = df.dropna(subset=['alert_type'])
```

- **fillna()**: Asigna un valor a todo hueco vacío.
- **dropna()**: Corta problemas de raíz eliminando filas.

One-Hot Encoding Dinámico

Transformando categorías alfabéticas a la matrix binaria:

```
df_encoded = pd.get_dummies(df,
                            columns=['alert_type'],
                            prefix='type',
                            dtype=int)
```

- Crea columnas como `type_Malware` con `1` o `0`.
- Listo para ser interpretado matemáticamente.

Escaladores (StandardScaler)

Emparejando la cancha para el algoritmo k-NN:

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
# El algoritmo aprende (fit) y transforma la data
X_scaled = scaler.fit_transform(X)
```

Regla de Oro en Machine Learning

¡NUNCA apliques `fit` en tus datos de Prueba (`X_test`)! Solo usa `transform()`, de lo contrario se filtra información del futuro (Data Leakage).