Preprocesamiento y Limpieza de Datos

Diagnóstico, Nulos, Codificación y Escalamiento (Teoría)

Clase Teórica - Semana 2

El Rompecabezas Dañado (Valores Nulos)

¿Qué hacer cuando faltan datos (`NaN`)?

- **Tirar a la Basura (`dropna`):** Eliminamos el registro. Fácil, pero perdemos información.
- **La Media Aritmética (`mean`):** Promediamos los datos. Peligroso si hay valores extremadamente altos que sesguen.
- **La Mediana (`median`):** El valor seguro del medio. Inmune a las anomalías extremas.

Cajas de Luz (One-Hot Encoding)

Los algoritmos no entienden palabras, solo números. Si tenemos las clases de malware: *Trojan*, *Ransomware*, *Phishing*.

Peligro (Label Encoding):
Trojan = 0, Ransomware = 1, Phishing = 2.
¡El algoritmo pensará que Phishing (2) "vale" más que Trojan (0)!

Solución (One-Hot):
Creamos 3 columnas binarias. Trojan = `[1, 0, 0]`. Phishing = `[0, 0, 1]`.
Equidad matemática.

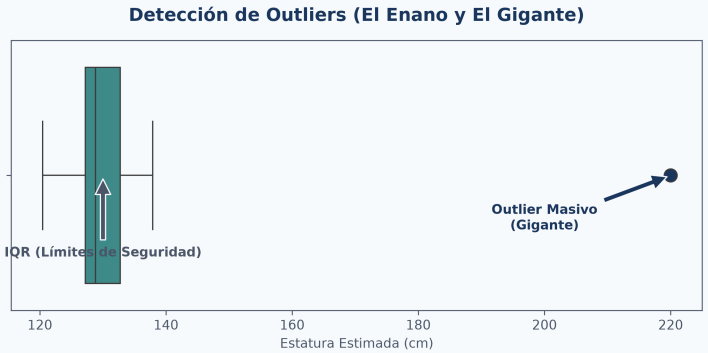
El Álbum de Stickers (Escalamiento Dimensional)

Si tienes Sueldo (0 a $1M) y Edad (0 a 100), el algoritmo que calcule "distancias" ignorará la Edad.

Soluciones Matemáticas

- **MinMaxScaler:** Acota matemáticamente los datos a un rango estricto $[0, 1]$. Destruido fácilmente si un Outlier gigante estira demasiado el marco.
- **StandardScaler:** Ajusta los datos para que tengan un promedio de 0 y varianza de 1. Se basa en cuánto te desvías del grupo.

Detección de Outliers (IQR)



Una frontera estadística nos ayuda a identificar si una transmisión de red de 1TB es un ataque (outlier) o comportamiento normal.