Práctica: Modelos Supervisados Clásicos

Scikit-Learn, Pandas y Visualización

Machine Learning para Ciberseguridad

Semana 3

Exploración del Dataset (Pandas)

Vamos a usar **pandas** para cargar e inspeccionar la data:

```
import pandas as pd

# Cargar dataset de URLs sospechosas
df = pd.read_csv("phishing_dataset.csv")

# Explorar las primeras filas
print(df.head())
```

Entrenamiento: k-NN en Scikit-Learn

La librería `scikit-learn` tiene una interfaz estándar: `fit()` para entrenar y `predict()` para clasificar.

```
from sklearn.neighbors import KNeighborsClassifier

# Instanciar el modelo (k=5 vecinos)
knn = KNeighborsClassifier(n_neighbors=5, metric='euclidean')

# Entrenar el modelo con los datos
knn.fit(X_train, y_train)

# Clasificar nuevas paginas web
predicciones = knn.predict(X_test)
```

Evaluación: La Matriz de Confusión

```
from sklearn.metrics import confusion_matrix,
    ConfusionMatrixDisplay
import matplotlib.pyplot as plt

# Generar la matriz cruzando realidad vs prediccion
cm = confusion_matrix(y_test, predicciones)

# Ploteo visual
disp = ConfusionMatrixDisplay(cm, display_labels=['Phishing', '
    Legitimo'])
disp.plot(cmap='Blues')
plt.show()
```